


# Deep Learning


## Chapter 3 활성화 함수, 오차 역전파, 경사하강법 (Activation Function, Back Propagation, Gradient Descent Algorithm)



START

- 활성화 함수의 개념을 이해 하고 종류를 알 수 있다.
- 오차역전파의 개념을 이해 할 수 있다.
- 다양한 경사하강법 종류를 알 수 있다.
- Keras를 활용해 다양한 경사하강법을 적용 할 수 있다.

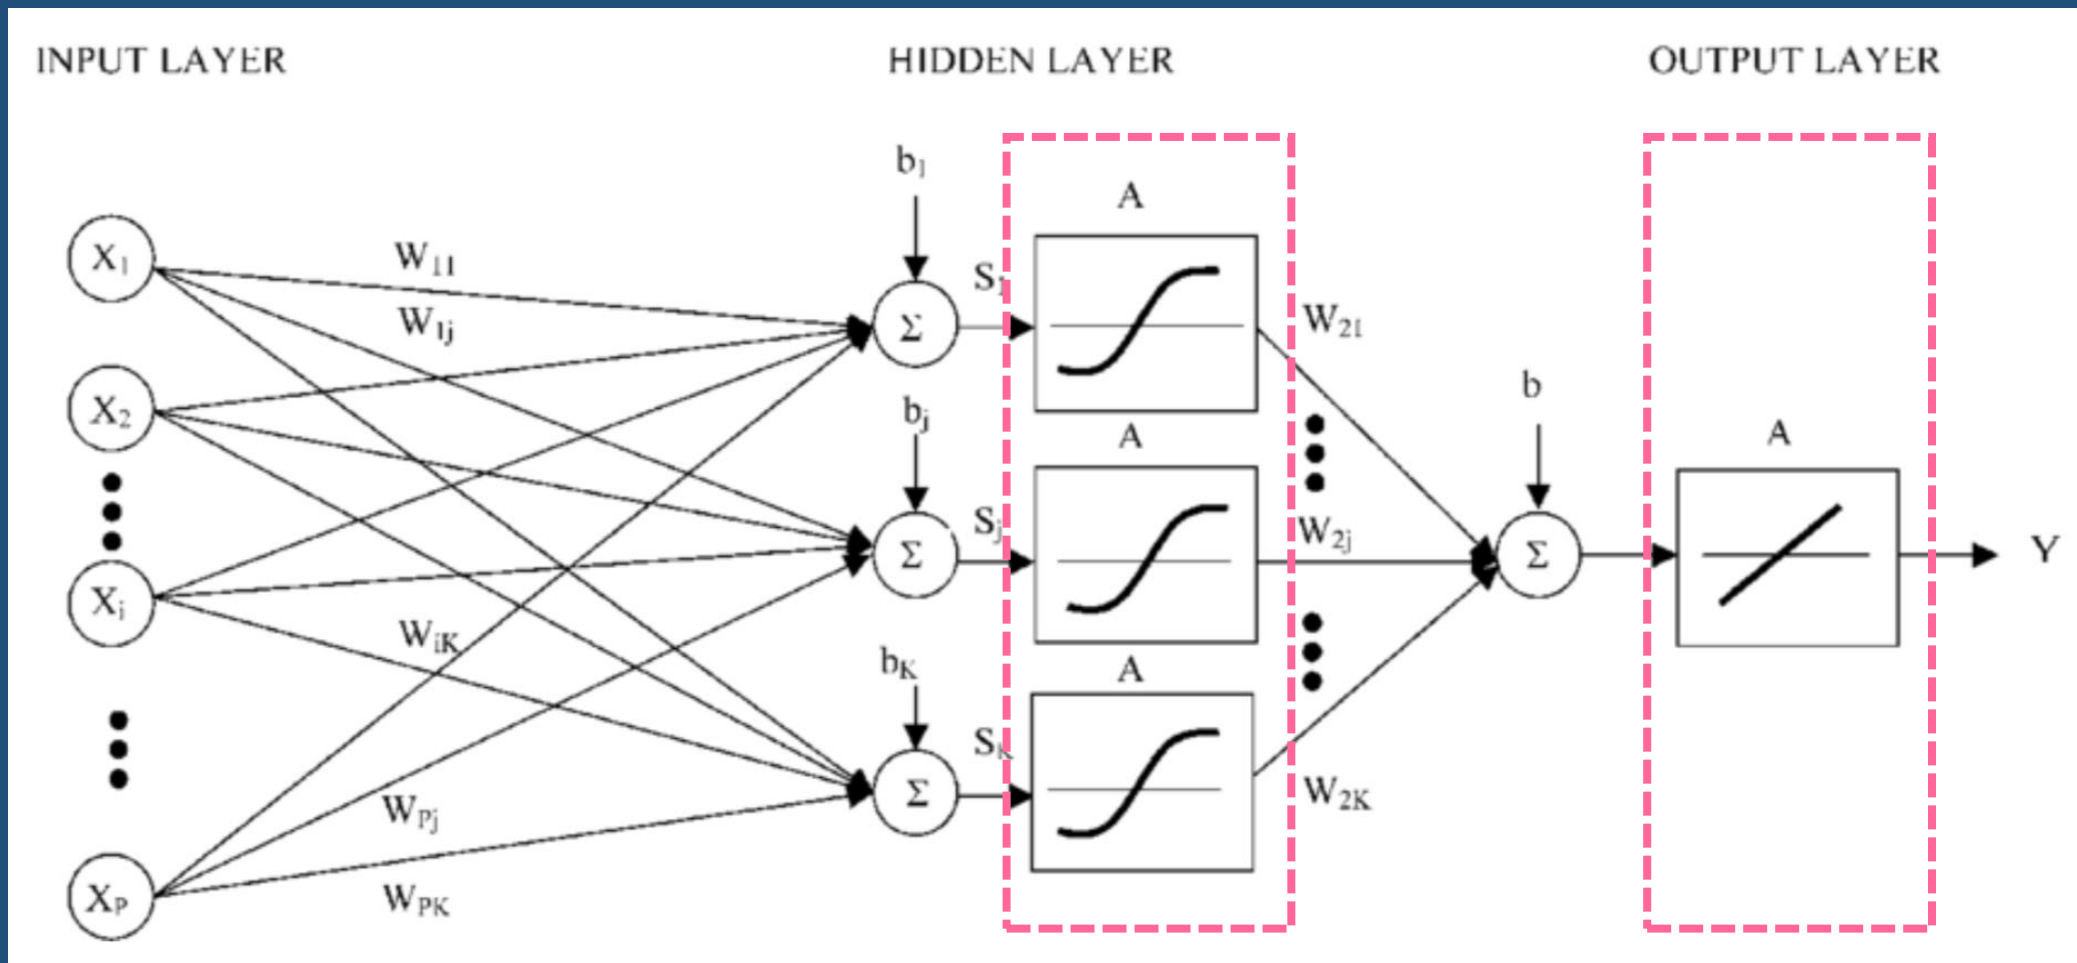
# 활성화함수(Activation)




## 활성화 함수(Activation Function)

- 신경망은 선형회귀와 달리 한 계층의 신호를 다음 계층으로 그대로 전달하지 않고 비 선형적인 활성화 함수를 거친 후에 전달한다.
- 이렇게 하는 이유는 신경망을 모방하여 사람처럼 사고하는 인공지능 기술을 구현하기 위함이다.
- 실제로 비선형의 활성화 함수를 도입한 신경망이 잘 동작하고 있다.


층에 따라 **다른** 활성화 함수 사용 가능



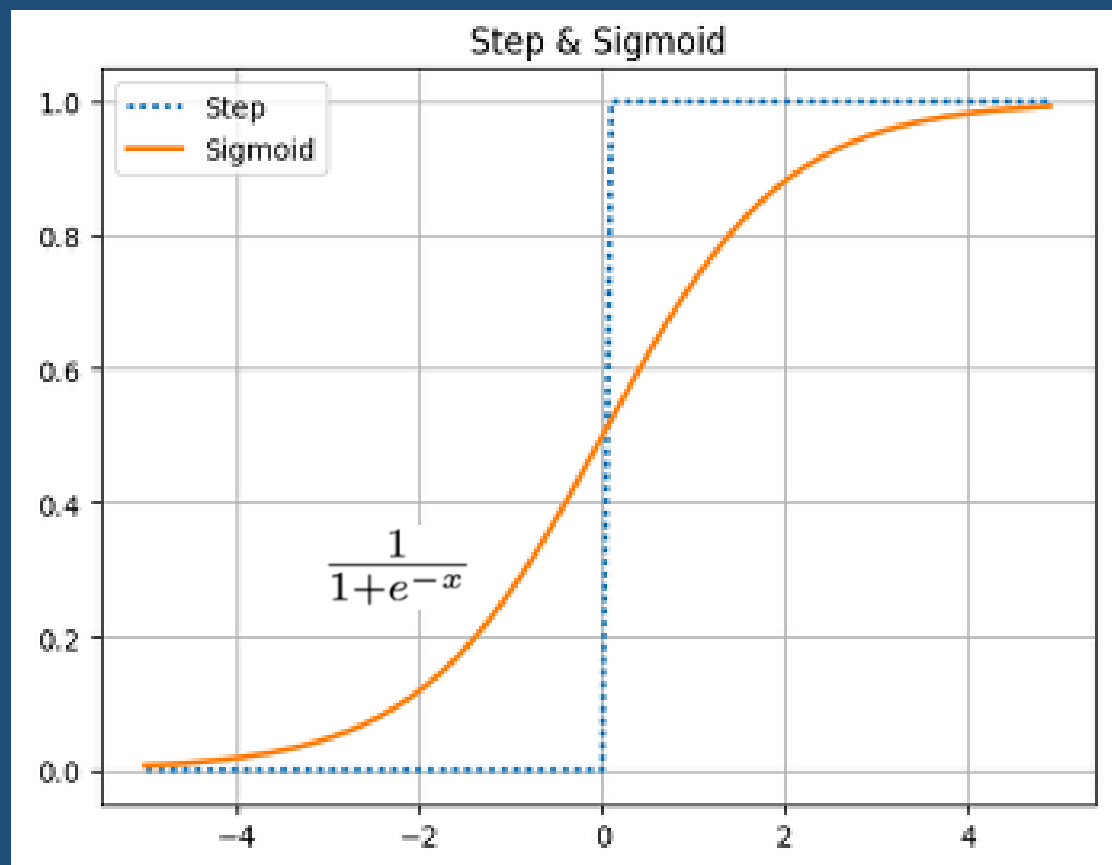
## Linear function(항등 함수=선형 함수) → 회귀



## Step function(계단 함수) → 분류의 초기 활성화 함수




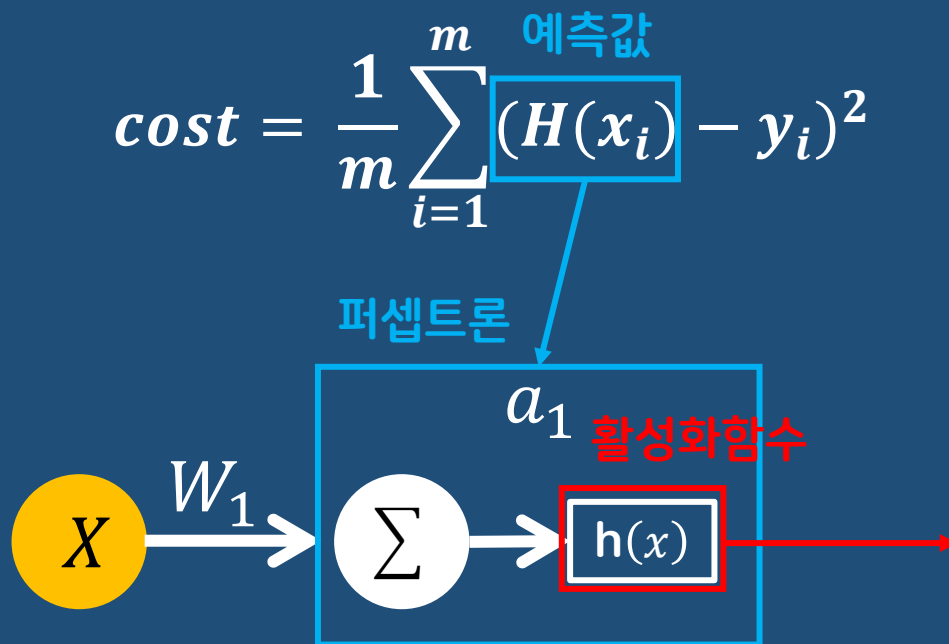
## Sigmoid 함수 → 이진분류





## 1. Step function과 Sigmoid의 차이

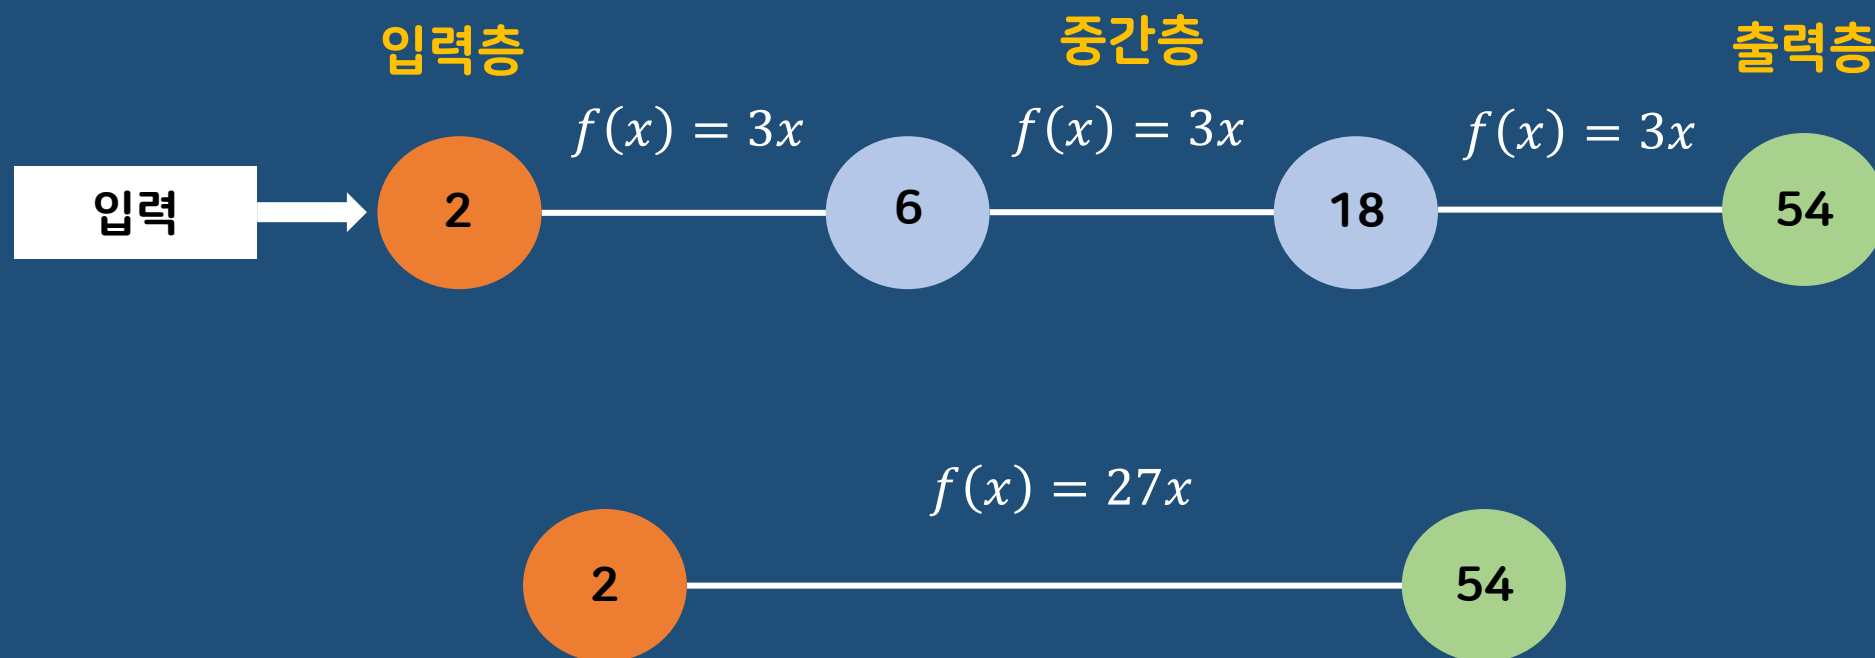
- 선형 모델이 학습하기 위해서 경사하강법(cost 함수를 미분)을 사용



## 2. 중간층에 활성화 함수로 비선형 함수를 사용하는 이유

- 계단 함수(step)와 시그모이드 함수(sigmoid)는 비선형 함수
- 활성화 함수로 선형함수(linear)  $h(x) = cx$  를 사용하면 중간층(은닉층)을 여러 개 구성한 효과를 살릴 수 없음

### 3. 중간층에 활성화 함수로 선형 함수를 사용하게 된다면 선형함수를 $h(x) = 3x$ 라고 가정 해보자!



중간층을 여러 개 쌓을 필요가 없음!

## 4. 다중분류 문제일 경우

- 다중분류 문제의 경우 정답 데이터를 원 핫 인코딩 해줘야 함
- 딥러닝 신경망에서는 각 레이블 값에 대한 확률 정보를 토대로 최종 분류를 진행함
- 각 레이블의 확률들을 알기 위해 출력층 퍼셉트론 개수를 레이블 개수와 맞춰야 함
- 원 핫 인코딩 된 정보와 출력층의 각 퍼셉트론이 예측한 확률과의 오차를 바탕으로 신경망이 학습하게 됨

## 소프트맥스(softmax) 함수 → 다중분류

다중분류에서 레이블 값에 대한 각 퍼셉트론의 **예측 확률의 합을 1로 설정**  
sigmoid에 비해 예측 오차의 평균을 줄여주는 효과

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

## 소프트맥스(softmax) 함수 코드 구현

```
1 import numpy as np
2
3 def softmax(x):
4     e_x = np.exp(x-x.max())
5     return e_x/e_x.sum()
```

```
1 x = np.array([1.0,1.0,2.0])
2 x
```

```
array([1., 1., 2.])
```

```
1 y = softmax(x)
2 y
```

```
array([0.21194156, 0.21194156, 0.57611688])
```

```
1 y.sum()
```

```
1.0
```

유 형	출력층 활성화 함수(activation)	손실함수(=비용함수)(loss)
회귀	linear(항등 함수)	mse
이진 분류	sigmoid(로지스틱 함수)	binary_crossentropy
다중 분류	softmax(소프트맥스 함수)	categorical_crossentropy


## 폐암 데이터 신경망으로 풀기 (이진 분류)



## 유방암 데이터 신경망으로 풀기 (이진 분류)

## iris 데이터 신경망으로 풀기 (다중 분류)

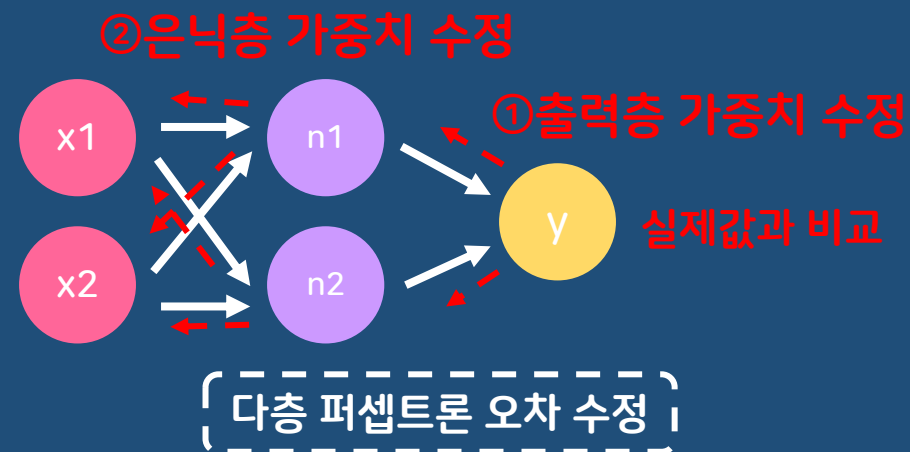
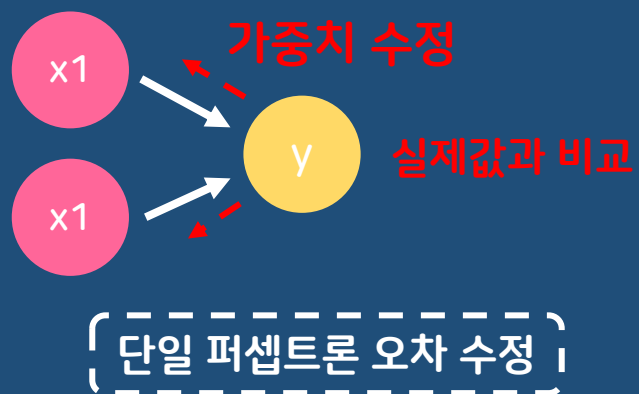

## 오차 역전파 (Back Propagation)



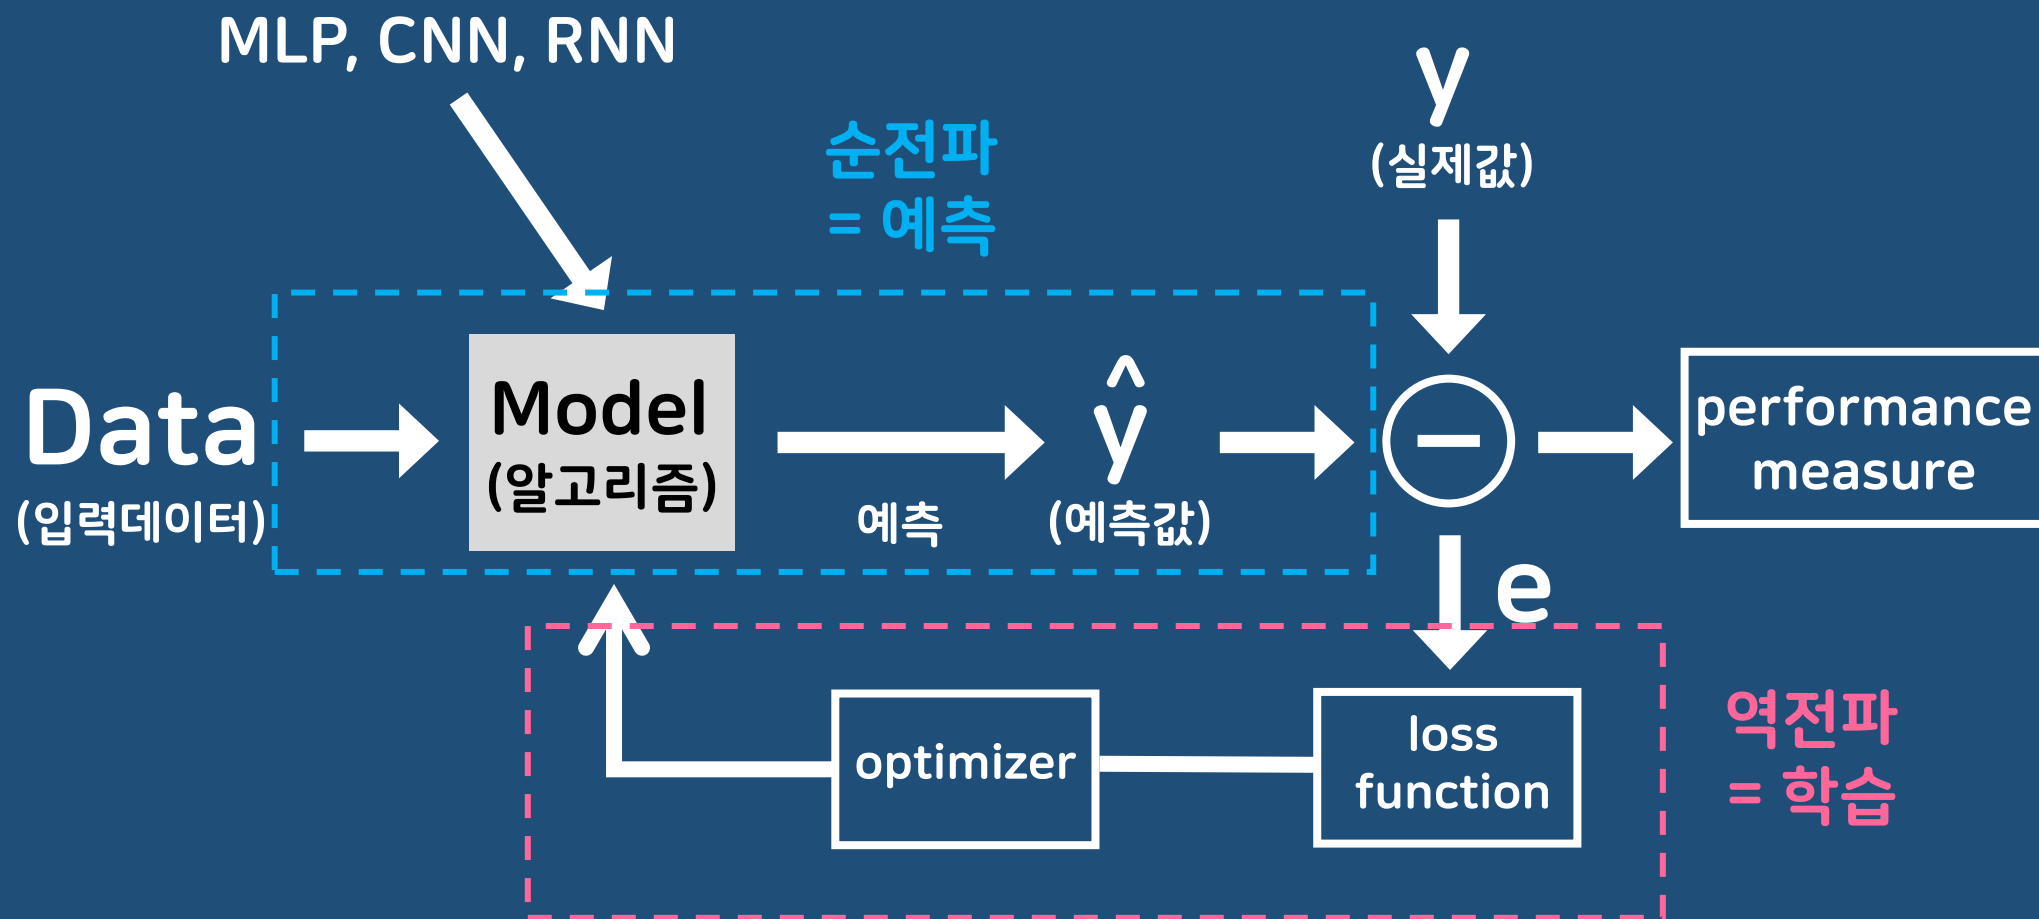
START

## 오차 역전파(Back Propagation)

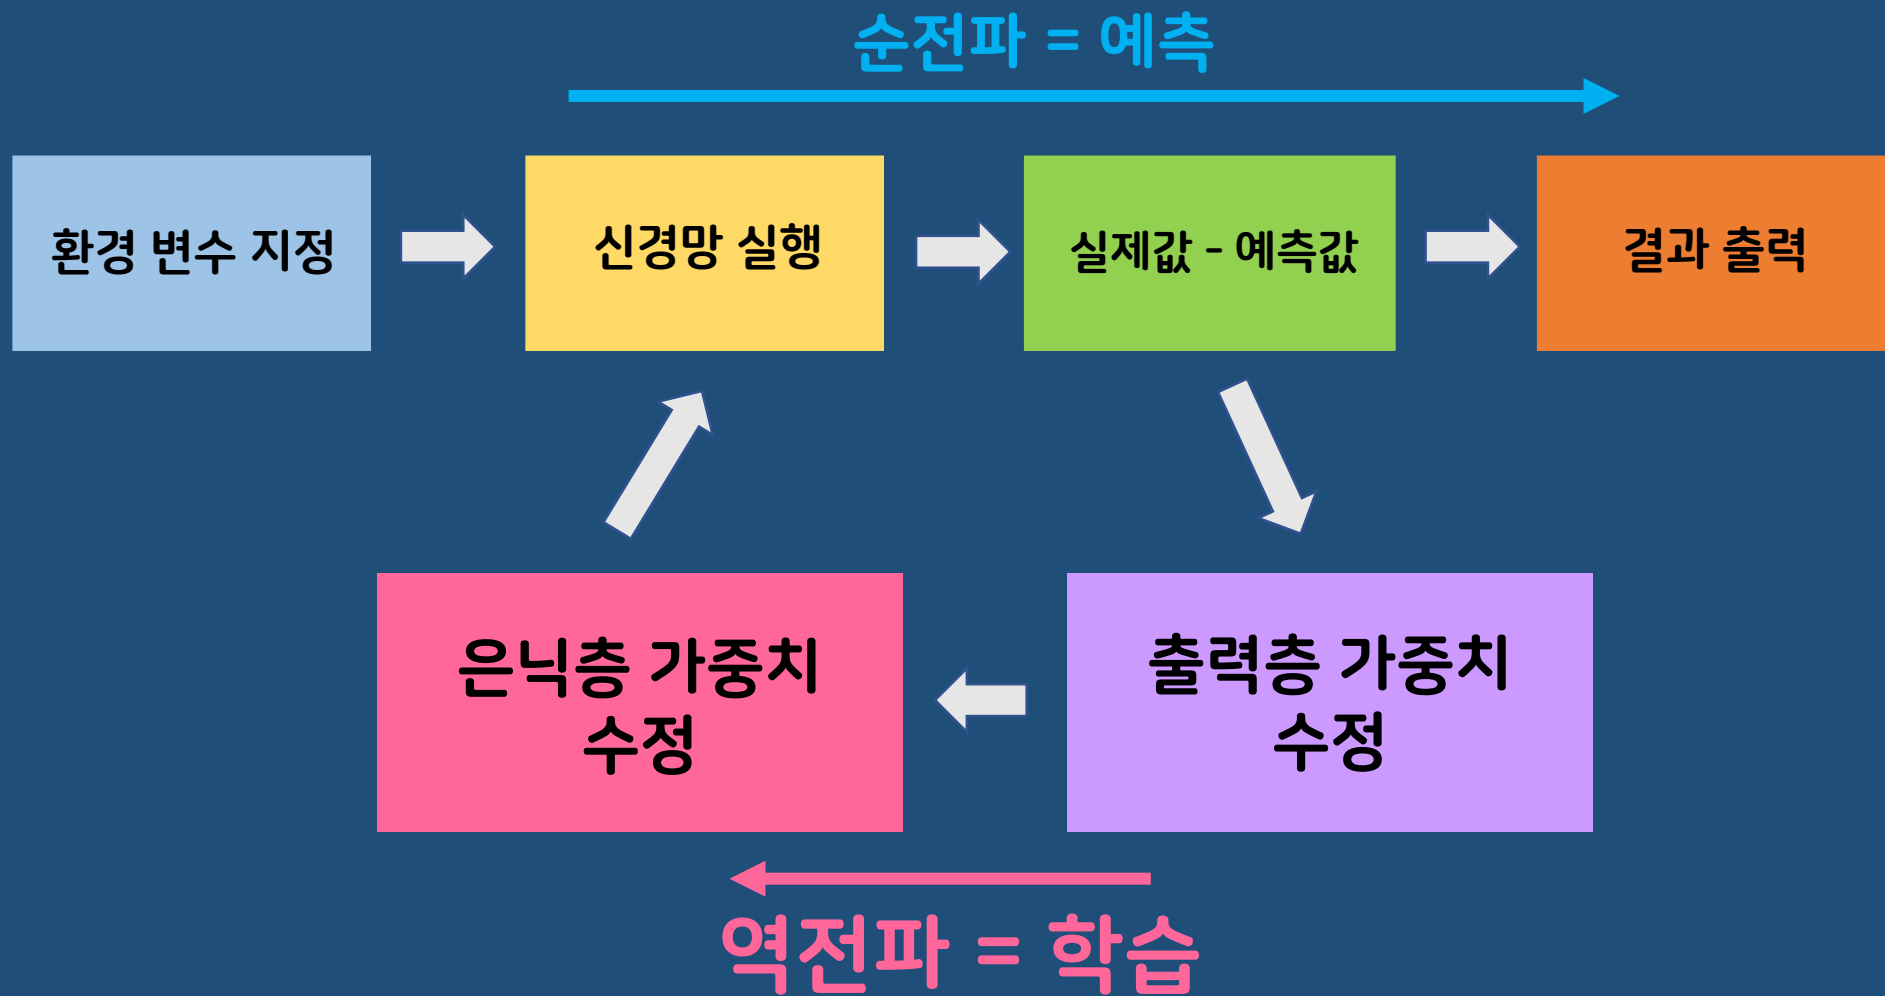
- **순전파** : 입력 데이터를 입력층에서부터 출력층까지 정방향으로 이동시키며 출력 값을 **추론**해 나가는 과정
- **역전파** : 출력층에서 발생한 에러를 입력층 쪽으로 전파시키면서 최적의 결과를 **학습**해 나가는 과정



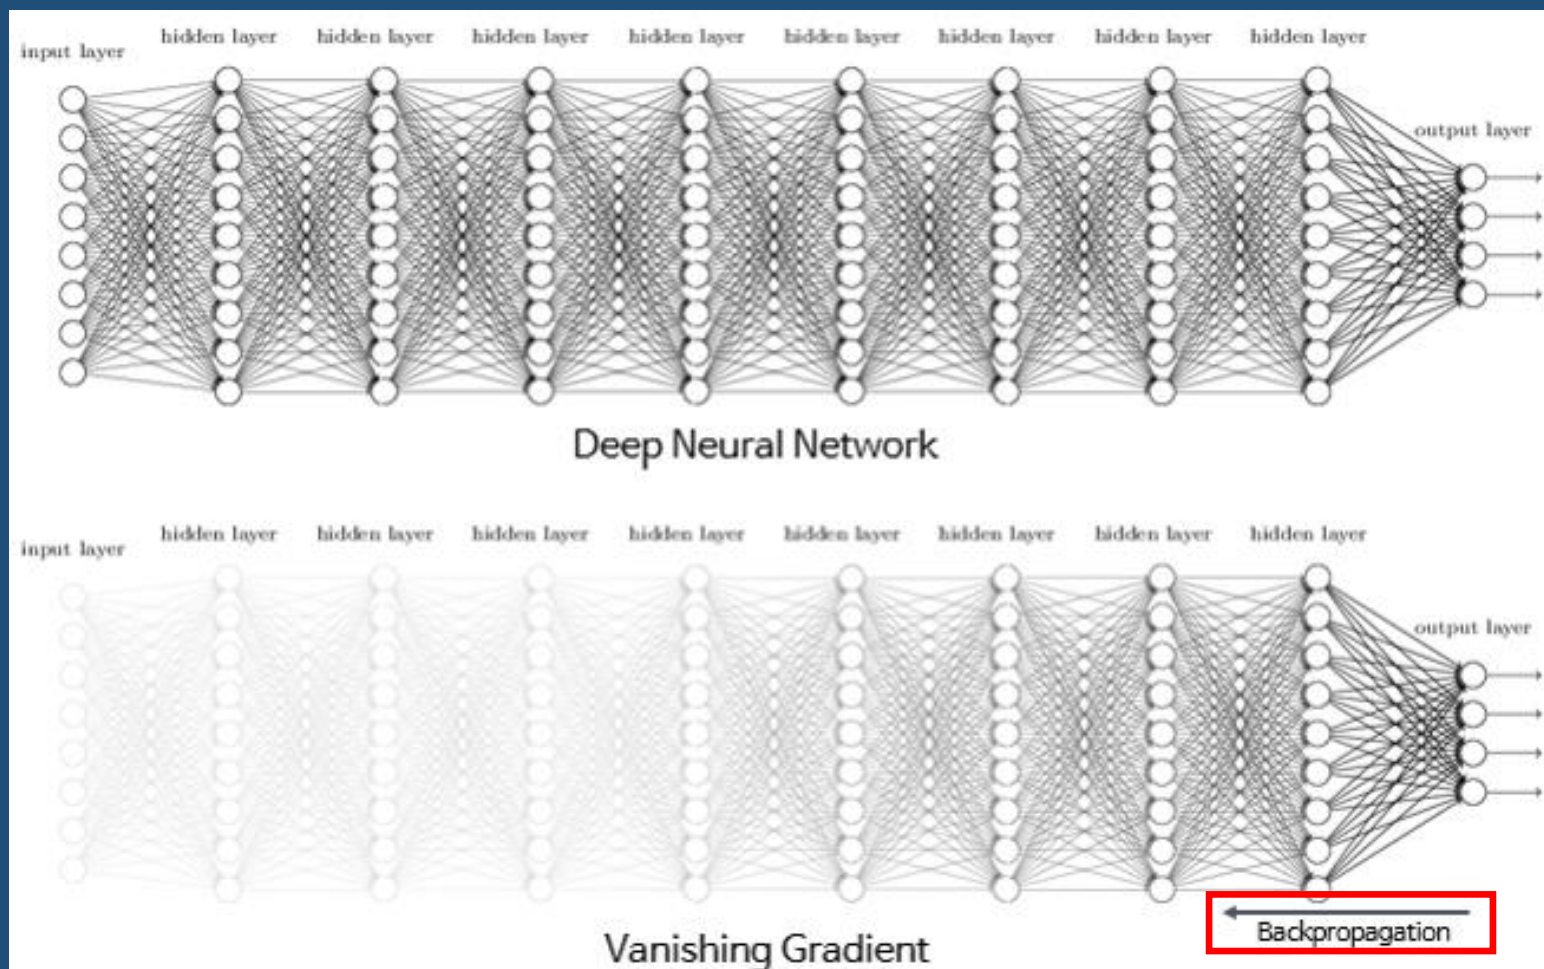
## 오차 역전파(Back Propagation)




## 오차 역전파(Back Propagation)



## 중간층 Sigmoid 함수의 문제점




## 중간층 Sigmoid 함수의 문제점






# 활성화 함수(Activation)의 종류




**Sigmoid**


$$\sigma(x) = \frac{1}{1+e^{-x}}$$

**tanh**


$$\tanh(x)$$

**ReLU**

$$\max(0, x)$$

**Leaky ReLU**


$$\max(0.1x, x)$$

**Maxout**


$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

**ELU**

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$





## 최적화 함수(Optimizer)



START


## 경사하강법(Gradient Descent Algorithm)





**경사하강법**  
(Gradient Descent)

전체 데이터를 이용해 업데이트

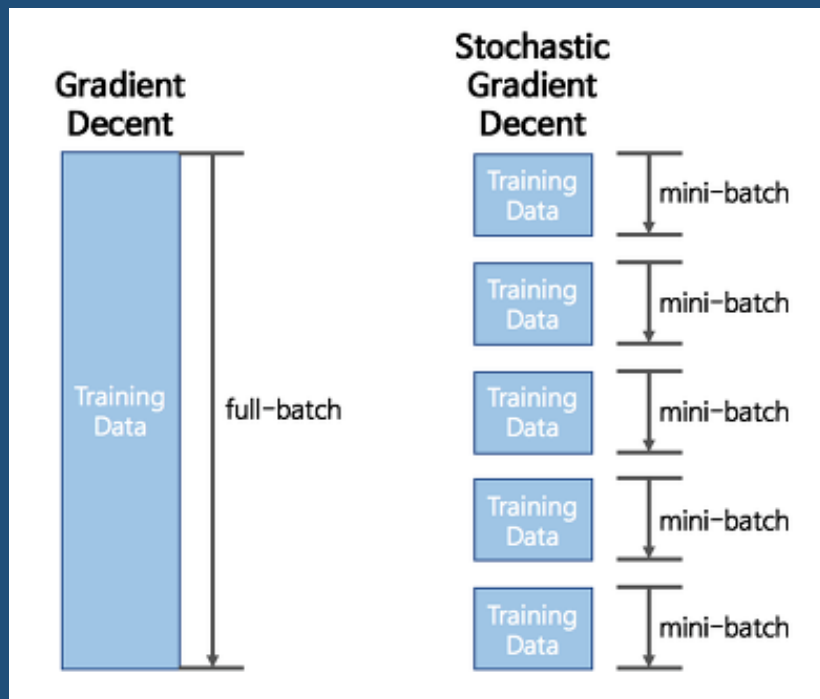


**확률적경사하강법**  
(Stochastic Gradient Descent)

확률적으로 선택된 일부 데이터를  
이용해 업데이트

## Batch\_size

일반적으로 PC 메모리의 한계 및 속도 저하 때문에 대부분의 경우에는 한번의 epoch에 모든 데이터를 한꺼번에 집어넣기가 힘들



- batch\_size를 줄임
  - 메모리 소모가 적음(pc성능이 안 좋을 때)

- batch\_size를 높임
  - 메모리 소모가 큼, 학습 속도가 빠름


→ batch\_size의 디폴트 값은 32이며  
일반적으로 32, 64가 많이 사용됨

# 최적화함수(Optimizer)의 종류



**확률적경사하강법**  
(Stochastic Gradient Descent)

확률적으로 선택된 일부 데이터를  
이용해 업데이트



**모멘텀**  
(Momentum)

경사 하강법에 관성을 적용해 업데이트  
현재 batch뿐만 아니라 이전 batch  
데이터의 학습 결과도 반영




## 특징 (Momentum)

- 가중치를 수정하기 전 이전 방향을 참고하여 업데이트
- 지그재그 형태로 이동하는 현상이 줄어든다
- $\alpha$ 는 Learning Rate,  $m$ 은 momentum 계수 (보통 0.9)



$$V(t) = m * V(t - 1) - \alpha \frac{\partial}{\partial w} Cost(w)$$
$$W(t + 1) = W(t) + V(t)$$






네스테로프 모멘텀  
(Nesterov Accelerated Gradient)  
개선된 모멘텀 방식

## 특징 (NAG)

- 업데이트 시 모멘텀 방식으로 먼저 더한 다음 계산
- 미리 해당 방향으로 이동한다고 가정하고 기울기를 계산해본 뒤 실제 계산에 반영
- 불필요한 이동을 줄일 수 있다


$$V(t) = m * V(t - 1) - \alpha \frac{\partial}{\partial (w + m * V(t - 1))} Cost(w)$$
$$W(t + 1) = W(t) + V(t)$$



에이다그래드  
(Adaptive Gradient)  
학습률 감소 방법을 적용해 업데이트

## 특징 (Adagrad)

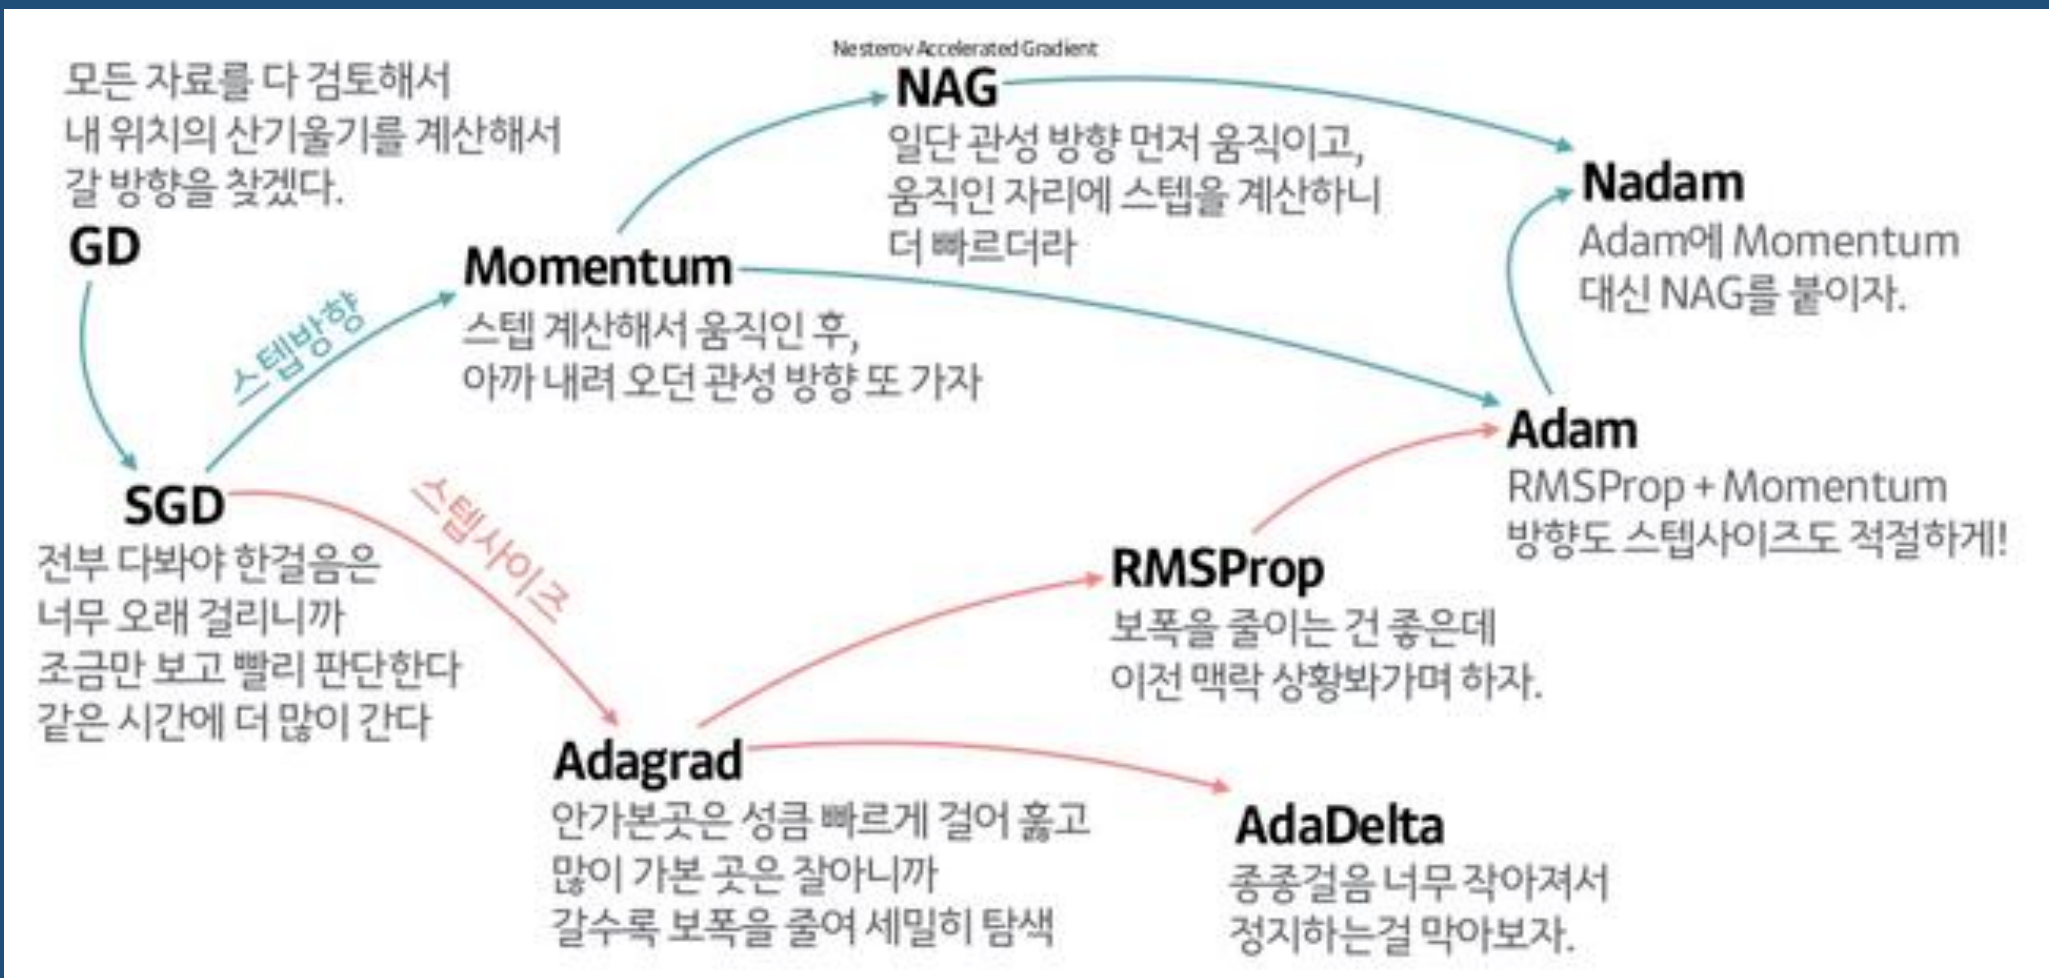
- 학습을 진행하면서 학습률을 점차 줄여가는 방법
- 처음에는 크게 학습하다가 조금씩 작게 학습한다
- 학습을 빠르고 정확하게 할 수 있다



$$G(t) = G(t-1) + \left( \frac{\partial}{\partial w(t)} \text{Cost}(w(t)) \right)^2$$
$$= \sum_{i=0}^t \left( \frac{\partial}{\partial w(i)} \text{Cost}(w(i)) \right)^2$$

$$W(t+1) = W(t) - \alpha * \frac{1}{\sqrt{G(t) + \epsilon}} * \frac{\partial}{\partial w(i)} \text{Cost}(w(i))$$

# 최적화함수(Optimizer)의 종류



출처 : <https://www.slideshare.net/yongho/ss-79607172>

## Keras

```
from tensorflow.keras import optimizers

opti = optimizers.SGD(learning_rate=0.01, momentum=0.9)

model.compile(loss='mse', optimizer=opti, metrics=['acc'])
```

Momentum

```
from tensorflow.keras import optimizers

opti = optimizers.SGD(learning_rate=0.01, momentum=0.9, nesterov=True)

model.compile(loss='mse', optimizer=opti, metrics=['acc'])
```

NAG

```
model.compile(loss="mse", optimizer="Adam", metrics=["acc"])
```

Adam

Adagrad, RMSprop, Adam 등은 이름으로 지정 가능

# Keras로 동물 이미지 데이터를 분류 모델을 만들어보자

# Keras로 MNIST 손글씨 이미지 데이터 분류 모델을 만들어보자



0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	38	48	48	22	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	62	97	198	243	254	254	212	27	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	67	172	254	254	225	218	218	237	248	40	0	21	164	187
0	0	0	0	0	0	0	0	0	0	0	0	89	219	254	97	67	14	0	0	92	231	122	23	203	236	59
0	0	0	0	0	0	0	0	0	0	0	25	217	242	92	4	0	0	0	4	147	253	240	232	92	0	0
0	0	0	0	0	0	0	0	0	0	0	101	255	92	0	0	0	0	0	105	254	254	177	11	0	0	0
0	0	0	0	0	0	0	0	0	0	0	167	244	41	0	0	0	7	76	199	238	239	94	10	0	0	0
0	0	0	0	0	0	0	0	0	0	0	192	121	0	0	2	63	180	254	233	126	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	190	196	14	2	97	254	252	146	52	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	130	225	71	180	232	181	60	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	130	254	254	230	46	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	6	77	244	254	162	4	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	110	254	218	254	116	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	131	254	154	28	213	86	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	66	209	153	19	19	233	60	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	142	254	165	0	14	216	167	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	90	254	175	0	18	229	92	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	26	229	249	176	222	244	44	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	73	193	197	134	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

# Keras로 패션 이미지 데이터 분류 모델을 만들어보자